

FINANCEPLUS.TECH

Web App Streamlit/Python per Archiviazione Intelligente Documentale

Specifica tecnica per programmatore + Prompt operativo per generare il file .py

Documento ripulito, ordinato e senza duplicazioni sostanziali. Sono stati eliminati solo i doppi, mantenendo i contenuti funzionali richiesti.

Obiettivo sintetico

Creare una web app Streamlit/Python capace di leggere, analizzare, classificare, rinominare e archiviare automaticamente documenti aziendali tramite OCR, HTR, IA e Intelligent Document Processing.

Indice operativo

1. Specifica tecnica per programmatore
2. Architettura funzionale della web app
3. Moduli obbligatori
4. Categorie documentali e dati da estrarre
5. Database e struttura cartelle
6. Apprendimento continuo e IA
7. Permessi, backup, report e integrazioni
8. Prompt operativo per generare il file .py

PARTE 1 - Specifica tecnica per programmatore

1. Obiettivo del progetto

Realizzare una web app in Streamlit/Python per la gestione intelligente dei documenti aziendali e professionali, capace di leggere, analizzare, classificare, rinominare e archiviare automaticamente file PDF, immagini, scansioni e documenti testuali.

La piattaforma dovrà utilizzare tecnologie di OCR, HTR, Intelligenza Artificiale e Intelligent Document Processing per riconoscere il contenuto dei documenti, estrarre i dati rilevanti, abbinarli al cliente corretto e salvarli in una struttura ordinata per cliente, anno, mese e tipologia documentale.

- OCR: riconoscimento ottico dei caratteri.
- HTR: riconoscimento del testo scritto a mano.
- IA: classificazione intelligente, estrazione dati e gestione casi incerti.
- IDP: processo intelligente di lettura, classificazione, workflow e archiviazione.
- Apprendimento continuo: miglioramento progressivo grazie alle correzioni dell'utente.

2. Priorità nel riconoscimento cliente

Il sistema deve dare priorità assoluta al riconoscimento del cliente tramite i seguenti dati:

- ragione sociale;
- partita IVA;
- codice fiscale;
- denominazione aziendale;
- amministratore;
- indirizzo sede;
- e-mail o PEC;
- altri dati identificativi presenti nel documento.

3. Struttura generale della web app

- unico file .py Streamlit;
- dashboard generale;
- importazione e catalogazione documenti;
- selezione di file singoli, cartelle intere e sottocartelle;
- lettura PDF digitali e scannerizzati;
- lettura immagini JPG, JPEG e PNG;
- lettura file TXT;
- OCR locale con pytesseract;
- eventuale OCR cloud/API;
- lettura PDF tramite PyMuPDF;
- classificazione automatica IA/rule-based;
- riconoscimento automatico del cliente;
- estrazione metadati;
- rinomina automatica dei file;
- archiviazione in cartelle cliente;
- database SQLite locale con predisposizione PostgreSQL;
- controllo duplicati con hash SHA256;
- ricerca full-text nell'archivio;
- coda documenti non riconosciuti o da verificare;
- esportazione CSV/Excel;
- report PDF;
- log attività;
- backup locale o cloud;
- integrazione Google Drive e pCloud;
- gestione permessi utenti;

- API o integrazioni future.

4. Dashboard

- numero totale documenti archiviati;
- numero clienti riconosciuti;
- documenti importati oggi;
- documenti duplicati bloccati;
- documenti non riconosciuti;
- documenti in coda da verificare;
- ultime attività eseguite;
- stato del database;
- stato del backup;
- statistiche per categoria documento.

5. Importazione e catalogazione

La web app deve consentire il caricamento di PDF digitali, PDF scannerizzati, immagini, file TXT, scansioni massive, documenti scaricati da e-mail, cartelle locali, sottocartelle, Google Drive e pCloud.

Dopo il caricamento, il sistema deve eseguire il seguente flusso operativo:

9. Leggere il documento.
10. Estrarre il testo.
11. Applicare OCR se necessario.
12. Riconoscere il tipo di documento.
13. Individuare cliente, P.IVA, CF e ragione sociale.
14. Estrarre i dati principali.
15. Verificare se il file è duplicato.
16. Rinominare automaticamente il file.
17. Archivarlo nella cartella corretta.
18. Registrare l'operazione nel database.
19. Inviare alla coda da verificare i documenti non riconosciuti.

6. Lettura documenti, OCR e HTR

- OCR locale tramite pytesseract;
- lettura PDF tramite PyMuPDF;
- supporto a documenti scannerizzati;
- supporto a immagini e fotografie;
- predisposizione a OCR cloud per maggiore precisione;
- riconoscimento documenti deteriorati o a bassa qualità;
- riconoscimento testo stampato;
- predisposizione HTR per testo scritto a mano;
- lettura layout del documento;
- riconoscimento tabelle, intestazioni, loghi, importi e riferimenti fiscali.

Regola tecnica OCR

L'app deve applicare automaticamente l'OCR solo quando il documento non contiene testo estraibile in modo diretto.

7. Intelligent Document Processing

- classificare automaticamente i documenti;
- estrarre dati strutturati da documenti non strutturati;
- gestire PDF con più pagine;
- riconoscere dati distribuiti su pagine diverse;
- leggere tabelle, intestazioni, importi e riferimenti fiscali;
- estrarre dati anche con interruzioni di pagina;
- automatizzare documenti deteriorati, scannerizzati o scritti a mano;

- collegare ogni documento al cliente corretto;
- alimentare workflow operativi specifici in base alla categoria del documento;
- migliorare nel tempo grazie alle correzioni dell'utente.

8. Categorie documentali

- visura camerale;
- bilancio;
- Centrale Rischi;
- DURC;
- documento di identità;
- contratto;
- fattura;
- estratto conto;
- preventivo;
- business plan;
- report bancario;
- dichiarazione fiscale;
- documento generico.

9. Dati da estrarre per categoria

Categoria	Dati da estrarre
Visura camerale	Ragione sociale, P.IVA, sede legale, amministratore, codice ATECO, capitale sociale
Bilancio	Anno, ricavi, utile/perdita, patrimonio netto, debiti, EBITDA stimato
Centrale Rischi	Mese, banca, accordato, utilizzato, scaduto, sconfini, garanzie
DURC	Azienda, protocollo, data validità, esito
Carta identità	Nome, cognome, scadenza, codice fiscale
Contratto	Parti, decorrenza, durata, importo, scadenze
Fattura	Fornitore, cliente, numero fattura, data, imponibile, IVA, totale
Estratto conto	Banca, IBAN, periodo, saldo iniziale, saldo finale
Preventivo	Fornitore, oggetto, importo, validità
Report bancario	Cliente, banca, importo richiesto, durata, garanzie
Business plan	Cliente, investimento, fabbisogno, durata, previsioni economiche
Dichiarazione fiscale	Contribuente, anno, imposte, reddito, protocollo
Documento generico	Cliente, data, parole chiave, possibile categoria

10. Riconoscimento cliente

- partita IVA;
- codice fiscale;
- ragione sociale;
- denominazione abbreviata;
- amministratore;
- indirizzo sede;
- e-mail o PEC;
- dati già presenti in anagrafica.

Se il cliente non esiste, il sistema deve creare automaticamente una nuova anagrafica cliente, inserendo i dati disponibili. Se il cliente non viene riconosciuto con certezza, il documento deve essere inserito nella coda da verificare.

11. Archiviazione automatica

Archivio_Documenti/
 Cliente_RagioneSociale_PIVA/

2026/
Luglio/
Visura/
Bilancio/
Centrale_Rischi/
DURC/
Contratti/
Fatture/
Estratti_Conto/
Preventivi/
Business_Plan/
Report_Bancari/
Dichiarazioni_Fiscali/
Altro/
Da_Verificare/

12. Rinomina automatica dei file

Schema consigliato:

RAGIONE_SOCIALE_categoria_documento_data.pdf

Esempi:

PELCOM_SRL_visura_07-05-2026.pdf
BEL_GARDEN_EUROPE_SRL_bilancio_31-12-2025.pdf

- evitare caratteri speciali;
- eliminare spazi errati;
- uniformare maiuscole/minuscole;
- evitare nomi duplicati;
- mantenere leggibilità professionale;
- conservare data, cliente e categoria.

13. Controllo duplicati

Il sistema deve calcolare per ogni documento un hash SHA256. Prima di archiviare un file, deve verificare se lo stesso hash è già presente nel database.

- bloccare il salvataggio;
- segnalare il duplicato;
- indicare dove si trova il file già archiviato;
- registrare l'evento nel log attività.

14. Database

La prima versione deve utilizzare SQLite locale, con predisposizione futura a PostgreSQL.

Tabella	Campi principali
Clienti	ID cliente, ragione sociale, P.IVA, CF, sede, amministratore, ATECO, e-mail, PEC, date creazione e aggiornamento
Documenti	ID documento, cliente, categoria, nome originale, nome archiviato, percorso, data documento, importo, hash, testo estratto, stato, data importazione
Coda da verificare	ID documento, file, testo estratto, categoria suggerita, cliente suggerito, motivo incertezza, stato lavorazione
Log attività	Data, utente, operazione, documento, risultato, note
Modello apprendimento	Parole chiave, categoria corretta, cliente corretto, regola appresa, data correzione, fonte correzione

15. Ricerca full-text

- ragione sociale;
- P.IVA;
- codice fiscale;
- amministratore;
- banca;
- importo;
- data;
- categoria documento;
- parola contenuta nel testo;
- numero fattura;
- IBAN;
- protocollo;
- ATECO.

La ricerca deve restituire documento, cliente associato, categoria, data, percorso file, anteprima del testo rilevante e pulsante per aprire o scaricare il documento.

16. Coda documenti da verificare

- visualizzare il documento;
- leggere il testo estratto;
- scegliere il cliente corretto;
- scegliere la categoria corretta;
- modificare i dati estratti;
- confermare l'archiviazione;
- salvare la correzione come regola futura.

17. Apprendimento continuo

- categoria corretta;
- cliente corretto;
- parole chiave rilevanti;
- P.IVA o CF riconosciuti;
- dati modificati;
- regola di archiviazione;
- associazione tra mittente, cliente e tipologia documento;
- riconoscimento di layout o contenuti simili.

Il modello deve diventare progressivamente più accurato nel tempo, usando dati confermati dall'utente, correzioni manuali e documenti già archiviati senza modifiche.

18. Integrazione IA

- leggere il contenuto del documento;
- classificare la categoria;
- estrarre dati chiave;
- riconoscere anomalie;
- proporre il cliente corretto;
- spiegare la classificazione;
- migliorare con le correzioni dell'utente;
- chiedere dove archiviare i documenti incerti;
- usare la risposta dell'utente per migliorare il comportamento futuro.

19. Report PDF, esportazioni e backup

Area	Funzioni richieste
Report PDF	Riepilogo importazioni, documenti archiviati, duplicati, non

	riconosciuti, clienti creati, errori, log e statistiche
Esportazioni	CSV, Excel e PDF per clienti, documenti, log, coda da verificare e statistiche
Backup	Backup locale, cartella esterna, Google Drive, pCloud o server aziendale di database, documenti, log, configurazioni e regole apprese

20. Permessi utenti

Ruolo	Permessi
Amministratore	Accesso completo, gestione database, utenti, cancellazioni, regole, backup, esportazioni e configurazioni
Operatore	Caricamento documenti, correzione coda da verificare, ricerca archivio, generazione report e consultazione autorizzata
Solo lettura	Consultazione clienti, consultazione documenti, ricerca e download autorizzato

21. API e integrazioni future

- Google Drive;
- pCloud;
- Gmail;
- PEC;
- scanner di rete;
- software gestionali;
- CRM;
- database PostgreSQL;
- API OCR cloud;
- modelli IA esterni;
- sistemi documentali aziendali.

22. Funzioni obbligatorie

Funzione	Obbligatoria
OCR su PDF e immagini	Si
Lettura documenti scannerizzati	Si
Classificazione automatica	Si
Estrazione metadati	Si
Riconoscimento cliente da P.IVA, CF o ragione sociale	Si
Rinomina automatica file	Si
Archiviazione per cliente	Si
Archiviazione per anno, mese e tipologia documentale	Si
Anti-duplicati con hash SHA256	Si
Coda da verificare	Si
Report attività	Si
Ricerca full-text	Si
Permessi utenti	Si
Backup cloud o locale	Si
Esportazione Excel / CSV	Si
Predisposizione API o integrazioni	Si
Apprendimento continuo dalle correzioni utente	Si
Predisposizione OCR cloud/API	Si
Predisposizione HTR per testo scritto a mano	Si

PARTE 2 - Prompt operativo per generare il file .py

Copiare e incollare il seguente prompt in ChatGPT/Codex per generare un file Python unico, professionale e completo.

Agisci come senior Python developer, esperto di Streamlit, OCR, Intelligent Document Processing, database SQLite/PostgreSQL, automazione documentale e workflow aziendali.

Devi realizzare un unico file Python chiamato `financeplus_archive_ai.py`.

Obiettivo:

Crea una web app Streamlit/Python per archiviazione intelligente documentale aziendale, capace di leggere, analizzare, classificare, rinominare e archiviare automaticamente PDF, immagini, scansioni e TXT.

Requisiti principali:

1. Dashboard iniziale con metriche: documenti archiviati, clienti riconosciuti, documenti importati oggi, duplicati, documenti non riconosciuti, coda da verificare, log attività e statistiche per categoria.
2. Importazione documenti da file singoli e da cartella intera, comprese sottocartelle.
3. Lettura PDF digitali con PyMuPDF.
4. OCR con pytesseract per PDF scannerizzati e immagini.
5. Predisposizione OCR cloud/API e HTR per testo scritto a mano.
6. Classificazione automatica rule-based e predisposta per IA.
7. Riconoscimento cliente con priorità a ragione sociale, P.IVA, codice fiscale, denominazione, amministratore, sede, e-mail e PEC.
8. Creazione automatica anagrafica cliente se non esiste.
9. Estrazione metadati per categoria documentale.
10. Rinomina automatica file con schema `RAGIONE_SOCIALE_categoria_documento_data.pdf`.
11. Archiviazione in cartelle: `Archivio_Documenti/Cliente_RagioneSociale_PIVA/Anno/Mese/Categoria/`.
12. Cartella `Da_Verificare` per documenti incerti.
13. Controllo duplicati tramite hash SHA256.
14. Database SQLite locale con tabelle clienti, documenti, coda_verificare, log_attività e regole_apprendimento.
15. Ricerca full-text nell'archivio per ragione sociale, P.IVA, CF, amministratore, banca, importo, data, categoria, parola nel testo, numero fattura, IBAN, protocollo e ATECO.
16. Coda documenti da verificare con possibilità di scegliere cliente, categoria, modificare dati e salvare la correzione come regola futura.
17. Apprendimento continuo basato su correzioni dell'utente, parole chiave, P.IVA, CF, cliente, categoria e associazione mittente/documento.
18. Report PDF con riepilogo documenti importati, archiviati, duplicati, non riconosciuti, clienti creati, categorie, errori, log e statistiche.
19. Esportazione CSV ed Excel per clienti, documenti, log e coda da verificare.
20. Backup locale e predisposizione Google Drive/pCloud.
21. Gestione ruoli base: Amministratore, Operatore, Solo lettura.
22. Predisposizione API future: Google Drive, pCloud, Gmail, PEC, scanner di rete, CRM, PostgreSQL, OCR cloud e modelli IA esterni.

Categorie da riconoscere:

- Visura camerale
- Bilancio
- Centrale Rischi
- DURC
- Documento identità
- Contratto
- Fattura
- Estratto conto
- Preventivo
- Business plan
- Report bancario
- Dichiarazione fiscale

- Documento generico

Dati da estrarre:

- Visura camerale: ragione sociale, P.IVA, sede legale, amministratore, ATECO, capitale sociale.
- Bilancio: anno, ricavi, utile/perdita, patrimonio netto, debiti, EBITDA stimato.
- Centrale Rischio: mese, banca, accordato, utilizzato, scaduto, sconfini, garanzie.
- DURC: azienda, protocollo, validita, esito.
- Carta identita: nome, cognome, scadenza, codice fiscale.
- Contratto: parti, decorrenza, durata, importo, scadenze.
- Fattura: fornitore, cliente, numero, data, imponibile, IVA, totale.
- Estratto conto: banca, IBAN, periodo, saldo iniziale, saldo finale.
- Preventivo: fornitore, oggetto, importo, validita.
- Report bancario: cliente, banca, importo richiesto, durata, garanzie.
- Business plan: cliente, investimento, fabbisogno, durata, previsioni economiche.
- Dichiarazione fiscale: contribuente, anno, imposte, reddito, protocollo.
- Documento generico: cliente, data, parole chiave, possibile categoria.

Vincoli tecnici:

- Il codice deve essere in un solo file .py.
- Usa Streamlit per interfaccia grafica.
- Usa SQLite come database iniziale.
- Usa pathlib per i percorsi.
- Usa hashlib per SHA256.
- Usa pandas per esportazioni CSV/Excel.
- Usa PyMuPDF per leggere PDF digitali.
- Usa pytesseract e Pillow per OCR immagini.
- Usa reportlab o fpdf per report PDF.
- Il programma deve creare automaticamente cartelle e database al primo avvio.
- Il codice deve essere commentato in italiano.
- Prevedi gestione errori chiara.
- Non eliminare file originali senza conferma.
- Se manca una libreria, mostra istruzioni di installazione.
- Inserisci una sezione laterale di configurazione percorsi, OCR, backup e ruoli.
- Inserisci pulsanti chiari: Dashboard, Importa documenti, Coda da verificare, Clienti, Documenti, Ricerca, Report, Backup, Impostazioni.

Output richiesto:

Genera direttamente il codice completo del file `financeplus_archive_ai.py`, pronto da copiare, salvare ed eseguire con:
`streamlit run financeplus_archive_ai.py`

Stile grafico:

Interfaccia professionale FinancePlus.Tech, palette blu/rame, card bianche, sidebar ordinata, titoli chiari, tabelle leggibili e messaggi operativi semplici.

PARTE 3 - Risultato atteso del file .py

- Web app Streamlit avviabile con un comando.
- Database SQLite e cartelle create automaticamente.
- Importazione da file e da cartella con sottocartelle.
- OCR e lettura PDF integrati.
- Classificazione documentale automatica.
- Riconoscimento cliente e creazione anagrafica.
- Rinomina e archiviazione automatica.
- Gestione duplicati tramite SHA256.

- Coda da verificare con apprendimento futuro.
- Report PDF ed esportazioni CSV/Excel.
- Predisposizione a cloud, PEC, Gmail, IA e PostgreSQL.

D'Angelo dr Danilo